补充材料：面向 V2X 风险判定的 Token 级语义传输

Changyu Zhang, Lingyun Lu, Wei Ni, Xiaoqiang Zhu

Appendix

下面证明式 选择间隙式（主文件式）。仿射标定以完整提示序列为锚点，因此根据式 语义代理误差界（主文件式），对任意 $\mathcal{T}\in\mathfrak{F}_k(m_{\max})$ 均有

$$|F^{(k)}_{\mathrm{T,true}}(\mathcal{T})-F^{(k)}_{\mathrm{T}}(\mathcal{T})|\le\varepsilon^{(k)}_{\mathrm{sem}}(m_{\max}). \tag{1}$$

再结合式 模型失配界（主文件式）并应用三角不等式，得到

$$|F^{(k)}_{\mathrm{R}}(\mathcal{T})-F^{(k)}_{\mathrm{T}}(\mathcal{T})|\le\varepsilon^{(k)}_{\mathrm{sem}}(m_{\max})+\varepsilon^{(k)}_{\mathrm{model}}\triangleq\overline{\varepsilon}_k. \tag{2}$$

由于 $\mathcal{T}^\star_{\mathrm{P}}$ 使代理效用达到最大，因此 $F^{(k)}_{\mathrm{T}}(\mathcal{T}^\star_{\mathrm{P}})\ge F^{(k)}_{\mathrm{T}}(\mathcal{T}^\star_{\mathrm{R}})$。在接收端效用差中分别加上并减去相应的代理效用，可得

$$\begin{aligned}&F^{(k)}_{\mathrm{R}}(\mathcal{T}^\star_{\mathrm{R}})-F^{(k)}_{\mathrm{R}}(\mathcal{T}^\star_{\mathrm{P}})\\&\le|F^{(k)}_{\mathrm{R}}(\mathcal{T}^\star_{\mathrm{R}})-F^{(k)}_{\mathrm{T}}(\mathcal{T}^\star_{\mathrm{R}})|\\&\quad+|F^{(k)}_{\mathrm{T}}(\mathcal{T}^\star_{\mathrm{P}})-F^{(k)}_{\mathrm{R}}(\mathcal{T}^\star_{\mathrm{P}})|\le2\overline{\varepsilon}_k.\end{aligned} \tag{3}$$

因此，式 选择间隙式（主文件式）得证。

在求解式 基础 LP（主文件式）之前，先剔除所有单独选择时就不满足容量约束的模式。若暂时去掉唯一的容量不等式，剩余可行域是各 Token 组单纯形的笛卡尔积。该乘积与一个活跃的容量超平面相交后，所得极点最优解中至多只有一个 Token 组取非整数值。否则，若同时存在两个分数组，就可以在两者之间构造一个非零的反向扰动，使容量约束和所有组约束均保持不变，这与极点的定义矛盾。唯一可能存在的分数组位于其单纯形的一条边上，因此其 LP 贡献不超过该组中最佳单独可行模式的价值。令 V_{I} 和 V_{f} 分别表示整数部分和分数部分的贡献，由主文件中的相应公式可得

$$F^{(k)}_{\mathrm{base},\tau}(\widehat{\boldsymbol{y}})\ge\max\{V_{\mathrm{I}},V_{\mathrm{f}}\}\ge\tfrac{1}{2}(V_{\mathrm{I}}+V_{\mathrm{f}})\ge\tfrac{1}{2}F^{(k)}_{\mathrm{base},\tau}(\boldsymbol{y}^\star_{\mathrm{base}}), \tag{4}$$

从而证明式 1/2 保证（主文件式）。另一方面，带耦合问题的最优解 $\boldsymbol{y}^\star$ 也是基础问题的一个可行解，因此

$$\begin{aligned}\overline{F}^{(k)}_{\tau}(\widehat{\boldsymbol{y}})&\ge F^{(k)}_{\mathrm{base},\tau}(\widehat{\boldsymbol{y}})\\&\ge\frac{1}{2}F^{(k)}_{\mathrm{base},\tau}(\boldsymbol{y}^\star)\\&\ge\frac{1}{2(1+\kappa_k)}\overline{F}^{(k)}_{\tau}(\boldsymbol{y}^\star),\end{aligned} \tag{5}$$

其中，首尾两个不等式均由式 夹逼关系（主文件式）得到。由于每一次被接受的局部操作都会严格增大 $\overline{F}^{(k)}_{\tau}$，上述下界在局部改进后仍然成立。又因为可行的 Token 与保护模式组合数是有限的，所以局部改进必将在有限步内终止。至此，式 耦合近似（主文件式）得证。

本文模型可以恢复若干有用的特殊情形。当 $\beta=0$ 时，式 期望效用（主文件式）退化为可加的多选择背包目标。当 $q^{(k)}_{i\ell,\tau}=1$ 且 $|\mathcal{R}|=1$ 时，原问题退化为带容量约束的 Token 选择。当 $\Delta r_k\to0$ 时，式 码本间隙界（主文件式）恢复连续速率自适应。在 CSI 完美且 $\varepsilon_{\mathrm{out}}\to0$ 时，可靠频谱效率退化为瞬时频谱效率。当信道分布歧义集仅包含一个元素时，式 中断分布偏移式（主文件式）退化为经过校准的条件中断模型。若 $\boldsymbol{\theta}^{(k)}_{\mathrm{T}}=\boldsymbol{\theta}_{\mathrm{R}}$ 且两侧提示序列分布一致，则 $\varepsilon^{(k)}_{\mathrm{model}}=0$。最后，当 $K=1$ 时，不再需要跨终端带宽分配，系统退化为单终端可靠性感知调度器。

以下为该小节在主文件中所略去的中间推导。

为使语义分数能够与任务损失直接比较，令 $\mathcal{P}^{(k)}_{\mathcal{T}}$ 表示将集合 $\mathcal{T}$ 之外的 Token 全部掩码后得到的提示序列，并在忽略无关加法常数的意义下，将发送端真实的保留效用定义为

$$F^{(k)}_{\mathrm{T,true}}(\mathcal{T})=-\mathcal{L}^{(k)}_{\mathrm{T}}(\mathcal{P}^{(k)}_{\mathcal{T}}). \tag{6}$$

本文利用验证集上的正仿射标定，把式 集合效用（主文件式）中的原始语义分数 $U^{(k)}_{\mathrm{T}}$ 映射到 NLL 量纲，标定后的效用记为 $F^{(k)}_{\mathrm{T}}$。仿射偏置以完整提示序列为锚点，使 $F^{(k)}_{\mathrm{T}}(\mathcal{P}^{(k)})=F^{(k)}_{\mathrm{T,true}}(\mathcal{P}^{(k)})$，而正比例系数可吸收到业务权重 ω_k 中。由此，

$$\Delta\mathcal{L}^{(k)}_{\mathrm{proxy}}(\mathcal{T})=F^{(k)}_{\mathrm{T}}(\mathcal{P}^{(k)})-F^{(k)}_{\mathrm{T}}(\mathcal{T}) \tag{7}$$

该量可作为提示剪枝所引起 NLL 增量的代理量，而对应的真实 NLL 增量为

$$\Delta\mathcal{L}^{(k)}_{\mathrm{true}}(\mathcal{T})=\mathcal{L}^{(k)}_{\mathrm{T}}(\mathcal{P}^{(k)}_{\mathcal{T}})-\mathcal{L}^{(k)}_{\mathrm{T}}(\mathcal{P}^{(k)}). \tag{8}$$

设共有 $m_k=N_k-|\mathcal{T}|$ 个 Token 被删除，并将这些 Token 的嵌入扰动拼接为向量 $\Delta\boldsymbol{\xi}^{(k)}$。由于不同 Token 的扰动位于互不重叠的坐标块中，且式 集合效用（主文件式）至多是二次的，因此，经过标定的代理剪枝损失可在删除扰动子空间上写成

$$\Delta\mathcal{L}^{(k)}_{\mathrm{proxy}}=\widehat{\boldsymbol{g}}^{(k)\top}\Delta\boldsymbol{\xi}^{(k)}+\frac{1}{2}\Delta\boldsymbol{\xi}^{(k)\top}\widehat{\boldsymbol{H}}^{(k)}\Delta\boldsymbol{\xi}^{(k)}. \tag{9}$$

令 $\boldsymbol{g}^{(k)}$ 和 $\boldsymbol{H}^{(k)}$ 分别表示同一删除扰动子空间上的真实一阶系数和二阶系数，并假设

$$\|\boldsymbol{g}^{(k)}-\widehat{\boldsymbol{g}}^{(k)}\|_2\le\varepsilon_{g,k},\qquad\|\boldsymbol{H}^{(k)}-\widehat{\boldsymbol{H}}^{(k)}\|_2\le\varepsilon_{H,k}. \tag{10}$$

进一步假设真实 Hessian 的 Lipschitz 常数为 $L_{3,k}$。式 系数偏差假设（本文件）中的系数偏差可利用留出的单 Token 删除样本和成对 Token 删除样本进行保守校准。根据 Taylor 定理，有

$$\begin{aligned}|\Delta\mathcal{L}^{(k)}_{\mathrm{true}}-\Delta\mathcal{L}^{(k)}_{\mathrm{proxy}}|\le{}&\varepsilon_{g,k}\|\Delta\boldsymbol{\xi}^{(k)}\|_2\\&+\frac{\varepsilon_{H,k}}{2}\|\Delta\boldsymbol{\xi}^{(k)}\|_2^2\\&+\frac{L_{3,k}}{6}\|\Delta\boldsymbol{\xi}^{(k)}\|_2^3.\end{aligned} \tag{11}$$

若每个被删除 Token 的嵌入扰动范数均不超过 d_k，则由坐标块互不重叠可得 $\|\Delta\boldsymbol{\xi}^{(k)}\|_2 \le \sqrt{m_k} d_k$。定义

$$\varepsilon_{\mathrm{sem}}^{(k)}(m_k) \triangleq \varepsilon_{g,k}\sqrt{m_k} d_k + \frac{\varepsilon_{H,k}}{2} m_k d_k^2 + \frac{L_{3,k}}{6} m_k^{3/2} d_k^3. \quad (12)$$

于是，式 二阶代理展开（本文件）右侧的误差上界不超过 $\varepsilon_{\mathrm{sem}}^{(k)}(m_k)$。给定允许的语义损失误差 δ_k，定义可保证的最大删除 Token 数

$$m_k^{\mathrm{cert}}(\delta_k) = \max\{m \in \{0,\dots,N_k\} : \varepsilon_{\mathrm{sem}}^{(k)}(m) \le \delta_k\}. \quad (13)$$

因此，只要 $m_k \le m_k^{\mathrm{cert}}(\delta_k)$，语义代理误差就不会超过预设容限 δ_k。这一结果明确给出了近似成立的范围：它同时取决于被删除 Token 的数量、一阶系数标定误差、因果耦合所对应的曲率误差以及更高阶的非线性交互。主文件相应小节还将给出独立条件 $\kappa_k = \beta d_{M,k}/2 < 1$，用于刻画相应的弱耦合范围。其取值分布与条件成立与否由主文件相应小节 D-3 的实验给出，从而避免该理论条件停留在未验证的假设层面。

以上讨论均假定收发模型一致。实际中，发送端与接收端可以采用不同的模型架构、参数规模、量化精度或提示序列分布。忽略与上文相同的无关加法常数，定义接收端效用 $F_{\mathrm{R}}^{(k)}(\mathcal{T}) = -\mathcal{L}_{\mathrm{R}}^{(k)}(\mathcal{P}_{\mathcal{T}}^{(k)})$。假设发送端与接收端之间的效用偏差具有如下统一上界：

$$\sup_{\mathcal{T}} |F_{\mathrm{R}}^{(k)}(\mathcal{T}) - F_{\mathrm{T,true}}^{(k)}(\mathcal{T})| \le \varepsilon_{\mathrm{model}}^{(k)}. \quad (14)$$

当两侧模型的参数一一对应且可以直接比较时，可采用如下充分上界：

$$\varepsilon_{\mathrm{model}}^{(k)} \le L_{\theta,k}\|\boldsymbol{\theta}_{\mathrm{T}}^{(k)} - \boldsymbol{\theta}_{\mathrm{R}}\|_2 + L_{P,k} d(\mathbb{P}_{\mathrm{T}}^{(k)}, \mathbb{P}_{\mathrm{R}}). \quad (15)$$

对于架构不同的模型，可用公共校准集上答案分布之间的全变差距离或基于 KL 散度的距离替代参数差异项。令 $\mathfrak{F}_k(m_{\max})$ 表示删除 Token 数量不超过 $m_{\max}$ 的可行集合族，并令 $\mathcal{T}_{\mathrm{P}}^{\star}$ 和 $\mathcal{T}_{\mathrm{R}}^{\star}$ 分别为该集合族上代理效用与接收端真实效用的最优解，则

$$F_{\mathrm{R}}^{(k)}(\mathcal{T}_{\mathrm{R}}^{\star}) - F_{\mathrm{R}}^{(k)}(\mathcal{T}_{\mathrm{P}}^{\star}) \le 2\left[\varepsilon_{\mathrm{sem}}^{(k)}(m_{\max}) + \varepsilon_{\mathrm{model}}^{(k)}\right]. \quad (16)$$

式 选择间隙式（主文件式）将发送端模型内部的语义代理误差，与收发模型差异及提示序列分布偏移造成的失配明确区分开来（证明见补充材料）。进一步地，把主文件中的相应公式用于单个 Token 的删除，并分别在完整提示序列和删除 Token 后的提示序列上应用式 模型失配界（主文件式），即可得到从梯度敏感度到下游任务误差的显式联系：

$$P_{e,\mathrm{R}}^{(k)}(\mathcal{P}_{-i}^{(k)}) \le \frac{1}{\log 2}\big[\mathcal{L}_{\mathrm{R}}^{(k)}(\mathcal{P}^{(k)}) + G_i^{(k)} + \tfrac{L_{H,k}}{2}\|\Delta\boldsymbol{e}_i^{(k)}\|_2^2 + 2\varepsilon_{\mathrm{model}}^{(k)}\big]. \quad (17)$$

因此，本文并未把 $G_i^{(k)}$ 直接解释为与 VQA 错误线性等价的量。它表示接收端 VQA 错误概率上界中可以通过 Token 选择进行控制的一阶主导项。

分别定义被调度的 Token 数量和相应的等效比特开销为

$$n_k(\boldsymbol{y}) = \sum_{i,\ell} y_{i\ell,\tau}^{(k)}, \qquad R_k(\boldsymbol{y}) = \sum_{i,\ell} r_{i\ell}^{(k)} y_{i\ell,\tau}^{(k)}. \quad (18)$$

给定 Token 数量上限 n 和可靠传输预算 C，最优语义性能前沿可表示为如下值函数：

$$\mathcal{V}_{k,\tau}(n,C) = \max_{\boldsymbol{y}^{(k)}} \ \overline{F}_{\tau}^{(k)}(\boldsymbol{y}^{(k)}) \quad \text{s.t.} \ \ n_k(\boldsymbol{y}) \le n, \ \ R_k(\boldsymbol{y}) \le C, \ \ y_{i\ell,\tau}^{(k)} \in \{0,1\}. \quad (19)$$

$\mathcal{V}_{k,\tau}(n,C)$ 关于 n 和 C 均单调不减。它在两个方向上的离散增量，分别表示多调度一个 Token 或多增加一个等效比特所带来的边际语义收益。这里，$T_s B_{k,\tau}$ 为可用的时频符号资源，C 为相应的可靠传输预算，二者的关系由式 可靠预算（主文件式）给出，而 C/T_s 即相应的可靠等效比特速率。

令 $\boldsymbol{y}_{\mathcal{V}}^{\star}$ 为式 语义速率前沿（本文件）的一个最优解，并以 $\mathcal{T}_{\tau}^{(k)}(\boldsymbol{y}_{\mathcal{V}}^{\star})$ 表示由该调度产生的随机成功接收 Token 集合。定义平均语义代理余项

$$\overline{\varepsilon}_{\mathrm{sem},k,\tau}(n,C) = \mathbb{E}\Big[\varepsilon_{\mathrm{sem}}^{(k)}\Big(N_k - |\mathcal{T}_{\tau}^{(k)}(\boldsymbol{y}_{\mathcal{V}}^{\star})|\Big)\Big|\widehat{h}_{\tau}^{(k)}\Big]. \quad (20)$$

若该最优解共调度 $n_\star = n_k(\boldsymbol{y}_{\mathcal{V}}^{\star})$ 个 Token，且其中至少一个 Token 发生残余解码失败的概率不超过 δ_{dec}，则由式 语义代理误差界（主文件式）的单调性可得如下可直接计算的上界：

$$\overline{\varepsilon}_{\mathrm{sem},k,\tau}(n,C) \le (1-\delta_{\mathrm{dec}})\varepsilon_{\mathrm{sem}}^{(k)}(N_k - n_\star) + \delta_{\mathrm{dec}}\varepsilon_{\mathrm{sem}}^{(k)}(N_k), \quad (21)$$

其中，根据并合界，$\delta_{\mathrm{dec}} \le \sum_{i,\ell} y_{\mathcal{V},i\ell,\tau}^{\star(k)}(1 - q_{i\ell,\tau}^{(k)})$。进一步结合式 VQA 错误界（主文件式）、式 标定损失式给出的标定损失恒等式、语义代理误差界以及模型失配界，可得到下游 VQA 性能的显式上界：

$$P_{e,k,\tau}^{\mathcal{V}}(n,C) \le \frac{1}{\log 2}\big[\mathcal{L}_{\mathrm{R}}^{(k)}(\mathcal{P}^{(k)}) + F_{\mathrm{T}}^{(k)}(\mathcal{P}^{(k)}) - \mathcal{V}_{k,\tau}(n,C) + \overline{\varepsilon}_{\mathrm{sem},k,\tau}(n,C) + 2\varepsilon_{\mathrm{model}}^{(k)} + \varepsilon_{\mathrm{ch},\tau}^{(k)}\big]. \quad (22)$$

上述结果由恒等式 $\mathbb{E}[\mathcal{L}_{\mathrm{R}}^{(k)}(\mathcal{P}_{\mathcal{T}}^{(k)})] = \mathcal{L}_{\mathrm{R}}^{(k)}(\mathcal{P}^{(k)}) + F_{\mathrm{R}}^{(k)}(\mathcal{P}^{(k)}) - \mathbb{E}[F_{\mathrm{R}}^{(k)}(\mathcal{T})]$ 以及对收发模型失配界的两次应用得到。其中，$P_{e,k,\tau}^{\mathcal{V}}$ 表示采用语义性能前沿最优调度时的 VQA 错误概率。若 NLL 等效效用的变化范围不超过 $\Delta_{F,k}^{\max}$，则可靠容量发生中断所引起的附加项满足 $\varepsilon_{\mathrm{ch},\tau}^{(k)} \le \varepsilon_{\mathrm{out}}\Delta_{F,k}^{\max}$。根据式 中断分布偏移式（主文件式），该结论以 $1-\delta_{\mathrm{amb}}$ 的置信度成立。需要强调的是，式 VQA 性能上界（主文件式）给出的是性能上界，而不是精确等式。该式从理论上刻画了 Token 数量、传输比特率与 VQA 性能之间的权衡。其可检验的定性推论是，在可靠预算内提高可传输的 Token 数量或等效比特率不会恶化可达的最优代理效用，而过度剪枝或采用过弱的保护模式会放大语义代理余项。主文件相应小节 C 的符号预算扫描与该节 D-2 的集合级可加性检验正是针对这两个推论设计的。当被调度的 n 个 Token 均成功接收时，式 平均语义余项（本文件）简化为 $\varepsilon_{\mathrm{sem}}^{(k)}(N_k - n)$。

本文并未根据某个 Token 优先级类别预先固定其保护速率。二元变量 $y_{i\ell,\tau}^{(k)}$ 允许系统在每个时隙内为每个 Token 单独选择保护模式，而有限集合 $\mathcal{R}$ 对应实际可用的调制编码码本。为量化离散码本相对于连续速率自适应的性能差

距，设连续速率 r 下的条件解码概率 $q_i^{(k)}(r,h)$ 随 r 单调不减，并关于 r 满足常数为 $L_{q,k}$ 的 Lipschitz 条件，而码本速率 $r_{i\ell}^{(k)}$ 处的取值即 $q_{i\ell,\tau}^{(k)}$。同时假设任一可行连续速率都可以向下舍入到一个码本速率，且两者之差不超过 Δr_k。定义

$$d_{M,k}=\max_i\left(\sum_{j>i}M_{ij}^{(k)}+\sum_{j<i}M_{ji}^{(k)}\right), \tag{23}$$

则向下舍入后的资源分配仍满足容量约束，并且

$$0\le\mathcal{V}_{k,\tau}^{\mathrm{cont}}(n,C)-\mathcal{V}_{k,\tau}^{\mathcal{R}}(n,C)\le N_k(1+\beta d_{M,k})L_{q,k}\Delta r_k. \tag{24}$$

这是因为，向下舍入使每个 Token 的接收程度至多变化 $L_{q,k}\Delta r_k$，记舍入后的接收程度为 $\widetilde{z}_i$，则 $|z_iz_j-\widetilde{z}_i\widetilde{z}_j|\le|z_i-\widetilde{z}_i|+|z_j-\widetilde{z}_j|$。对所有与 Token 关联的因果耦合权重求和，即可得到式 码本间隙界（主文件式）。因此，随着码本粒度不断细化，动态离散保护的性能将逐渐逼近连续速率自适应。

令 ω_k 表示终端 k 的业务权重，B 表示系统总带宽。为兼顾任务效用和终端间的服务公平性，每个时隙求解如下联合优化问题：

$$\max_{\boldsymbol{B}_\tau,\boldsymbol{y}_\tau}\quad\sum_{k=1}^{K}\omega_k\overline{F}_\tau^{(k)}(\boldsymbol{y}^{(k)})+\vartheta\sum_{k=1}^{K}\log(B_{k,\tau}+\varepsilon_B) \tag{25}$$

$$\text{s.t.}\quad\sum_{k=1}^{K}B_{k,\tau}\le B,\quad B_{k,\tau}\ge0, \tag{26}$$

$$,\qquad,\quad y_{i\ell,\tau}^{(k)}\in\{0,1\}.$$

目标函数中，前一项用于最大化各终端的加权任务效用，后一项是比例公平正则项。参数 $\vartheta\ge0$ 调节任务准确率与服务公平性之间的权衡，$\varepsilon_B>0$ 则保证带宽为零时对数项仍为有限值。Jain 公平指数仅作为实验评估指标使用。关于 Pareto 改进的判断必须基于对 ϑ 进行扫描后得到的完整性能前沿，而不能仅依据某一个工作点。

问题 联合优化问题（主文件式）采用集中式形式书写，以便清楚呈现系统级目标，但实际实现可以分解。接收端只负责在各终端之间协调共享带宽变量 $\{B_{k,\tau}\}$，而每个终端 k 在本地并行计算其私有的 Token 与保护模式选择 $\boldsymbol{y}^{(k)}$。因此，本文所谓“联合”，是指带宽分配会综合考虑所有终端局部响应所体现的语义价值，并不意味着终端必须在调度前把候选 Token 或 Token 嵌入上传给接收端。

固定 $B_{k,\tau}$ 后，终端在 $n=N_k$、$C=C_\tau^{(k)}$ 处的离散优化最优值记为 $V_\tau^{(k)}(B_{k,\tau})=\mathcal{V}_{k,\tau}(N_k,C_\tau^{(k)})$。进一步在足够细的资源粒度上，对相邻的可行 Token 与保护模式调度进行时间共享，并以 $\widetilde{V}_\tau^{(k)}(B_{k,\tau})$ 表示由此得到的凹闭包。该时间共享可通过 OFDM 资源块或微时隙实现，从而避免把阶梯状的离散值函数直接当作可微函数处理。令 $\mu_{k,\tau}^\star$ 表示相应连续松弛问题的最优乘子。对于可微点，根据包络定理有

$$\frac{\partial\widetilde{V}_\tau^{(k)}(B_{k,\tau})}{\partial B_{k,\tau}}=T_s\mu_{k,\tau}^\star c_\varepsilon^{(k)}(\widehat{h}_\tau^{(k)}). \tag{27}$$

在不可微点，式 值包络式（本文件）右侧仍是一个有效次梯度。外层时间共享松弛是凹优化问题。当 $\vartheta>0$ 时，对数正则项使目标函数在带宽单纯形上严格凹。因此，该问题的 KKT 条件不仅是必要条件，而且是充分条件，所得带宽分配并非经验性的启发式规则。

由此，终端 k 的带宽边际语义价值可写为 $g_{k,\tau}(B_{k,\tau})=\omega_kT_s\mu_{k,\tau}^\star(B_{k,\tau})c_\varepsilon^{(k)}(\widehat{h}_\tau^{(k)})$。所有获得正带宽的活跃终端均满足

$$g_{k,\tau}+\frac{\vartheta}{B_{k,\tau}+\varepsilon_B}=\nu_\tau,\qquad B_{k,\tau}>0, \tag{28}$$

其中，ν_τ 取值应使各终端获配带宽之和等于 B。结合时间共享值函数的分段常数次梯度，可通过对 ν_τ 进行一维搜索求解式 带宽 KKT 条件（主文件式）。在实际资源块量化时，再选择距离最近的可行时间共享点。由此，原先固定的 $p_k|\widehat{h}_\tau^{(k)}|$ 分配规则被替换为直接从联合目标函数推导出的带宽分配方法。

为保证系统能够按时隙因果运行，终端 k 只需上报当前的对偶迭代值 $\mu_{k,\tau}$，以一个标量概括其私有候选 Token 池的边际资源压力。接收端将该语义价格报告与 CSI 估计相结合，得到

$$\widehat{g}_{k,\tau}=\omega_kT_s\mu_{k,\tau}\,c_\varepsilon^{(k)}(\widehat{h}_\tau^{(k)}), \tag{29}$$

随后以 $\widehat{g}_{k,\tau}$ 替代式 带宽 KKT 条件（主文件式）中的精确边际语义价值。当语义价格报告固定时，活跃终端的带宽分配具有如下闭式表达：

$$\widehat{B}_{k,\tau}=\left[\frac{\vartheta}{\nu_\tau-\widehat{g}_{k,\tau}}-\varepsilon_B\right]^+,\qquad\nu_\tau>\widehat{g}_{k,\tau}, \tag{30}$$

其中，ν_τ 用于保证式 带宽约束（主文件式）成立。算法收敛后，$\mu_{k,\tau}=\mu_{k,\tau}^\star(B_{k,\tau})$，此时式 语义价格上报式（主文件式）恢复为精确次梯度。式 对偶更新式（主文件式）在相邻时隙之间更新语义价格，并将更新结果用于下一时隙的需求上报。这样便无须在获得当前资源授权之前，预先上报一个本身依赖该授权的 Token 选择结果，从而避免控制流程中的循环依赖。

语义价格上报不精确所造成的近似误差同样可以量化。令 $\boldsymbol{B}_\tau^\star$ 满足使用精确边际价值时的 KKT 条件，令 $\widehat{\boldsymbol{B}}_\tau$ 满足使用上报值时的 KKT 条件，并在 $\widehat{\boldsymbol{B}}_\tau$ 处定义梯度误差 $\boldsymbol{e}_{g,\tau}=\widehat{\boldsymbol{g}}_\tau-\boldsymbol{g}_\tau(\widehat{\boldsymbol{B}}_\tau)$。比例公平的外层目标 $J_\tau(\boldsymbol{B})$ 是参数为 σ_B 的强凹函数，且

$$\sigma_B\ge\frac{\vartheta}{(B+\varepsilon_B)^2},\qquad\vartheta>0. \tag{31}$$

比较这两个 KKT 系统对应的变分不等式，可得

$$\|\widehat{\boldsymbol{B}}_\tau-\boldsymbol{B}_\tau^\star\|_2\le\frac{\|\boldsymbol{e}_{g,\tau}\|_2}{\sigma_B},\qquad J_\tau(\boldsymbol{B}_\tau^\star)-J_\tau(\widehat{\boldsymbol{B}}_\tau)\le\frac{\|\boldsymbol{e}_{g,\tau}\|_2^2}{\sigma_B}. \tag{32}$$

因此，当终端上报的语义价格精确时，在线分配规则能够精确求解松弛后的联合目标。当上报存在误差时，带宽偏差和目标函数差距均由式 上报间隙界（本文件）显式控制。若 $\vartheta=0$，式 带宽 KKT 条件（主文件式）仍是必要的次梯度条件，但此时不再保证解的唯一性，强凹性误差界也不再适用。